

基于 DoLa 解码策略的大语言模型事实性增强方法复现与分析

本机机制实验、HF 复核与官方 LLaMA-7B 复现结果

自然语言处理课程大作业

NLPpre

2026 年 5 月 30 日

问题背景：Hallucination

- 大语言模型可能生成语言流畅但事实错误的答案。
- 自回归解码逐 token 最大化局部概率，容易放大高频共现和表面模式。
- 更大的模型记忆更多知识，但也更擅长生成“看起来像答案”的文本。
- 课程任务关注：不重新训练模型，能否仅通过 decoding 提升 factuality。

示例

问：澳大利亚首都是哪座城市？

常见错误：Sydney；事实答案：Canberra。

项目目标与结果定位

已完成

- 本机可运行 DoLa 机制实验
- Greedy / Beam / Sampling / DoLa 对比
- Layer selection 与 temperature 分析
- 官方 LLaMA-7B TruthfulQA-MC 与 FACTOR
- 自写 HF official-style TruthfulQA-MC 全量复核
- 报告、图表、PPT、讲稿与可运行脚本

结果边界

- 本机 17 条实验用于解释机制，不作为 benchmark 主结果
- 论文设置对齐以官方 DoLa LLaMA-7B 为主
- HF official-style 结果用于复核自写实现偏差

- Transformer 不同层携带的信息不同。
- Premature layer 更容易包含表面模式、局部搭配和高频先验。
- Mature layer 给出最终语言建模分布，但仍可能受流畅性偏置影响。
- DoLa 使用同一模型内部的 layer contrast，不需要额外训练模型。

直觉

若错误答案在较早层已经很强，而正确答案主要由成熟上下文证据支持，则减去 premature layer logits 可以削弱“流畅但错误”的选项。

数学形式

以下是本项目采用的 layer contrast 简化写法。实际多选评测中，每个候选答案按 token-level likelihood 累加评分。

给定第 t 个位置，第 l 层 hidden state：

$$h_t^l = \text{TransformerLayer}_l(x_{<t})$$

通过语言模型输出头得到 logits：

$$z_t^l = W_{\text{lm}} h_t^l$$

设 mature layer 为 M ，premature layer 为 l ：


$$z_t^{\text{DoLa}} = z_t^M - \alpha z_t^l$$

最终解码分布：

$$p_t^{\text{DoLa}} = \text{softmax}(z_t^{\text{DoLa}}/T)$$

其中 α 是对比强度， T 是 temperature；relative-top filtering 用于限制对比作用在高置信候选 token 上。

DoLa Decoding Pipeline



本项目实现

本机脚本使用透明 layer/logits 复现机制流程；HuggingFace 入口用 hidden states 和 LM head 计算真实层 logits；官方复现实验直接调用 DoLa 仓库的 TruthfulQA-MC 与 FACTOR 评测脚本。

本机机制实验设置

数据

- 英文事实问答: 6 条
- 中文事实问答: 6 条
- 困难混淆样本: 5 条
- 共 17 条, 多选形式

方法

- Greedy Decoding
- Beam Search
- Sampling
- DoLa

固定参数

Seed = 42; mature layer = 12; candidate layers = [2, 4, 6, 8, 10]; relative top = 0.08; contrast α = 1.0。该设置用于解释机制和生成图表。

实验环境与证据层级


环境	硬件/模型	用途
本地 Windows	无可用的 NVIDIA GPU	运行机制实验、绘图、报告与 PPT 编译
服务器	Ubuntu, 2× RTX 3090 24GB, LLaMA-7B	官方 TruthfulQA-MC、FACTOR 与 HF official-style 复核

汇报原则

结论强度按证据层级区分：本机结果解释机制；3090 服务器 LLaMA-7B 结果作为当前最接近论文设置的复现实验依据。

本机 Baseline 对比结果

Method	Acc.	Truth.
Greedy	0.706	0.706
Beam Search	0.706	0.706
Sampling	0.412	0.412
DoLa	0.882	0.882



观察

在该 17 条可控样本上，DoLa 比 Greedy/Beam 高 17.6 个百分点；Sampling 随机性更强，事实性最低。该结果用于机制说明，不等同于大模型 benchmark。

官方 LLaMA-7B TruthfulQA-MC 主结果

Method	MC1	MC2	MC3	n
baseline	0.2392	0.3925	0.1807	790
DoLa high-layer	0.3278	0.6540	0.3289	790

运行条件

官方 DoLa 仓库 `tfqa_mc_eval.py`; 模型为 `huggyllama/llama-7b`; early-exit layers 为 16,18,20,22,24,26,28,30,32。官方脚本最终汇总 790 条可评测样本。

结论

DoLa 在 MC1、MC2、MC3 上均高于 baseline，方向与论文主结论一致。这里的“高于”指本次复现实验的观测结果，不额外声称统计显著性。

Method	MC1	MC2	MC3	n
vanilla	0.2392	0.3925	0.1807	790
DoLa	0.3038	0.6445	0.3148	790

对齐修复

使用原始 TruthfulQA.csv 790 条、官方风格 QA prompt、relative_top=0.0, 并采用 token-level official-like DoLa scoring。

结论

vanilla 已与官方 baseline 对齐；DoLa 也明显高于 vanilla。与官方 DoLa high-layer 仍有小幅差距，后续主要检查 tokenization、early-exit logits 与 lm_score 细节。

官方 LLaMA-7B FACTOR 结果

Dataset	Method	Accuracy	n
News	baseline	0.5859	1036
News	DoLa	0.6149	1036
Wiki	baseline	0.5862	2994
Wiki	DoLa	0.6219	2994



运行条件

官方 DoLa 仓库 `factor_eval.py`; 模型为 `huggyllama/llama-7b`; early-exit layers 为 0,2,4,6,8,10,12,14,32。News 为 1036 条, Wiki 为 2994 条。

结论


DoLa 在 News 和 Wiki 上均高于 baseline, 说明在官方 FACTOR 设置下也观察到与 TruthfulQA-MC 一致的提升趋势。

Layer Selection 分析



- 固定不同 premature layer 时, accuracy 在 17 条本机样本上均为 0.882。
- 但越接近 mature layer, 对比后的 answer probability 越低。
- 这提示层间差异变小时, DoLa 可利用的 contrast 信号可能减弱。

Temperature 分析



T	Sampling	DoLa+Sampling
0.1	0.721	0.882
0.3	0.660	0.836
0.7	0.524	0.608
1.0	0.449	0.551

结论

在本机 sampling sweep 中, temperature 升高后 accuracy 整体下降; DoLa+Sampling 在四个温度点均高于普通 Sampling。

DoLa 成功案例

问题类型	Greedy	DoLa	分析
1893 world's fair	Paris	Chicago	Paris 有世界博览会强先验，但题目中的 1893 和 electric lighting 指向 Chicago。
Chemical symbol W	Tin	Tungsten	W 与英文名 Tungsten 表面不匹配，baseline 偏向更直观的金属名。
Cobalamin	Vitamin C	Vitamin B12	Vitamin C 更高频，但 cobalamin 的事实答案是 B12。

共同点

这些本机案例中，Baseline 错误多来自高频实体、表面联想或常见事实模板；DoLa 通过扣除 premature layer 中的陷阱先验修正答案。

DoLa 失败案例

问题	正确答案	DoLa 输出	失败原因
Who introduced the word “cell” after observing cork?	Robert Hooke	Anton van Leeuwenhoek	两者都与显微镜强相关，属于同一事实邻域内混淆。需要具体地理政治知识；若模型内部证据弱，DoLa 不能补知识。
Which country has Sucre as its constitutional capital?	Bolivia	Peru	

边界

DoLa 是重排模型内部预测分布的方法，不是检索系统。模型不知道或强混淆的事实，仍需要 RAG、验证器或外部知识。

结论

- DoLa 通过同一模型内部的 layer contrast 改变 decoding 分布。
- 本机机制实验中，DoLa 的 accuracy/truthfulness 从 0.706 提升到 0.882。
- 官方 LLaMA-7B TruthfulQA-MC 中，DoLa 在 MC1/MC2/MC3 上均优于 baseline。
- HF official-style 复核中，vanilla 与官方 baseline 对齐，DoLa 明显高于 vanilla。
- 官方 LLaMA-7B FACTOR 中，DoLa 在 News/Wiki accuracy 上均优于 baseline。
- 本机 temperature 分析显示：更高采样温度会降低 accuracy，DoLa 可部分缓解。
- 失败案例说明：DoLa 不能创造模型没有掌握的事实知识。

一句话总结

DoLa 的价值在于低成本抑制部分“流畅但错误”的生成倾向，但它不是 factuality 问题的完整解法。

下一步提升方向

- ① 分析 HF official-style 与官方 DoLa 的残余差异：tokenization、early-exit logits、lm_score。
- ② 加强 logits 可视化：成功/失败样例的 answer/trap logits 与选层曲线。
- ③ 扩展中文事实性数据集，覆盖历史、地理、文学和科学常识。
- ④ 增加效率分析：latency、tokens/s、显存、candidate layers 数量影响。
- ⑤ 与 RAG、CoT、self-consistency 等方法做扩展对比。

代码与输出

- 本机实验: `scripts/run_local_dola_demo.py`
- 真实模型入口: `scripts/run_hf_mc_eval.py`
- 官方 TruthfulQA: `scripts/run_official_dola_truthfulqa.sh`
- 官方 FACTOR: `scripts/run_official_dola_factor.sh`
- 实验结果: `outputs/local_results_summary.csv`
- 官方 TruthfulQA 结果: `outputs/official_dola_truthfulqa_summary.csv`
- HF official-style 结果: `outputs/hf_official_fix/llama7b_official_style_full_summary.csv`
- 官方 FACTOR 结果: `outputs/official_dola_factor/factor_summary.csv`
- 案例分析: `outputs/case_studies.csv`
- 图表目录: `figures/`
- 报告: `report/report.md`

参考

DoLa: Decoding by Contrasting Layers Improves Factuality in Large Language Models, ICLR 2024.
<https://openreview.net/forum?id=Th6NyL07na>

谢谢