

基于 DoLa 解码策略的大语言模型事实性增强方法复现与分析

当前本机可复现实验结果汇报

自然语言处理课程大作业

NLPpre

2026 年 5 月 26 日

汇报结构

- ① 背景与目标
- ② DoLa 方法
- ③ 实验设置
- ④ 实验结果
- ⑤ 案例分析
- ⑥ 结论与后续

问题背景：Hallucination

- 大语言模型可能生成语言流畅但事实错误的答案。
- 自回归解码逐 token 最大化局部概率，容易放大高频共现和表面模式。
- 更大的模型记忆更多知识，但也更擅长生成“看起来像答案”的文本。
- 课程任务关注：不重新训练模型，能否仅通过 decoding 提升 factuality。

示例

问：澳大利亚首都是哪座城市？

常见错误：Sydney；事实答案：Canberra。

项目目标与当前状态

已完成

- DoLa decoding pipeline 实现
- Greedy / Beam / Sampling / DoLa 对比
- Layer selection 分析
- Temperature 分析
- 成功与失败案例分析
- 报告、图表、可运行脚本

当前限制

- 当前机器未检测到 `nvidia-smi`
- 未安装 `torch/transformers`
- 本次结果是本机可复现实验，不是 7B GPU 真模型结果
- 已提供 HuggingFace/TruthfulQA 真实模型入口

- Transformer 不同层携带的信息不同。
- Premature layer 更容易包含表面模式、局部搭配和高频先验。
- Mature layer 给出最终语言建模分布，但仍可能受流畅性偏置影响。
- DoLa 使用同一模型内部的 layer contrast，不需要额外训练模型。

直觉

若错误答案在较早层已经很强，而正确答案主要由成熟上下文证据支持，则减去 premature layer logits 可以削弱“流畅但错误”的选项。

数学形式

给定第 t 个位置, 第 l 层 hidden state:

$$h_t^l = \text{TransformerLayer}_l(x_{<t})$$

通过语言模型输出头得到 logits:

$$z_t^l = W_{\text{lm}} h_t^l$$

设 mature layer 为 M , premature layer 为 l :


$$z_t^{\text{DoLa}} = z_t^M - \alpha z_t^l$$

最终解码分布:

$$p_t^{\text{DoLa}} = \text{softmax}(z_t^{\text{DoLa}}/T)$$

其中 α 是对比强度, T 是 temperature。

DoLa Decoding Pipeline



本项目实现

本机脚本使用透明 layer/logits 模拟复现上述流程；GPU 脚本使用 HuggingFace 模型 hidden states 和 lm_head 计算真实层 logits。

实验设置

数据

- 英文事实问答: 6 条
- 中文事实问答: 6 条
- 困难混淆样本: 5 条
- 共 17 条, 多选形式

方法

- Greedy Decoding
- Beam Search
- Sampling
- DoLa

固定参数

Seed = 42; mature layer = 12; candidate layers = [2, 4, 6, 8, 10]; relative top = 0.08; contrast α = 1.0。


项目	当前检测结果
OS	Windows 10
Python	3.13.12
GPU	未检测到 <code>nvidia-smi</code>
已安装	<code>numpy</code> , <code>pandas</code> , <code>matplotlib</code>
未安装	<code>torch</code> , <code>transformers</code> , <code>datasets</code>

说明

因环境限制，本 PPT 使用当前可复现实验结果；后续 GPU 验证将用 `scripts/run_hf_mc_eval.py` 跑 TruthfulQA。

Baseline 对比结果



Method	Acc.	Truth.
Greedy	0.706	0.706
Beam Search	0.706	0.706
Sampling	0.412	0.412
DoLa	0.882	0.882



观察


DoLa 在当前实验中比 Greedy/Beam 高 17.6 个百分点; Sampling 随机性更强, 事实性最低。

Layer Selection 分析



- 固定不同 premature layer 时, accuracy 在小数据集上均为 0.882。
- 但越接近 mature layer, 对比后的 answer probability 越低。
- 说明层间差异变小时, DoLa 可利用的 contrast 信号会减弱。

Temperature 分析



T	Sampling	DoLa+Sampling
0.1	0.721	0.882
0.3	0.660	0.836
0.7	0.524	0.608
1.0	0.449	0.551

结论

Temperature 越高，多样性上升但事实性下降；DoLa 在各温度下仍优于普通 Sampling。

DoLa 成功案例

问题类型	Greedy	DoLa	分析
1893 world's fair	Paris	Chicago	Paris 有世界博览会强先验，但题目中的 1893 和 electric lighting 指向 Chicago。
Chemical symbol W	Tin	Tungsten	W 与英文名 Tungsten 表面不匹配，baseline 偏向更直观的金属名。
Cobalamin	Vitamin C	Vitamin B12	Vitamin C 更高频，但 cobalamin 的事实答案是 B12。

共同点

Baseline 错误多来自高频实体、表面联想或常见事实模板；DoLa 通过扣除 premature layer 中的陷阱先验修正答案。

DoLa 失败案例

问题	正确答案	DoLa 输出	失败原因
Who introduced the word “cell” after observing cork?	Robert Hooke	Anton van Leeuwenhoek	两者都与显微镜强相关，属于同一事实邻域内混淆。需要具体地理政治知识；若模型内部证据弱，DoLa 不能补知识。
Which country has Sucre as its constitutional capital?	Bolivia	Peru	

边界

DoLa 是重排模型内部预测分布的方法，不是检索系统。模型不知道或强混淆的事实，仍需要 RAG、验证器或外部知识。

结论

- DoLa 通过同一模型内部的 layer contrast 改变 decoding 分布。
- 当前本机实验中，DoLa 的 accuracy/truthfulness 从 0.706 提升到 0.882。
- Temperature 分析显示：随机性增强会降低 factuality，DoLa 可部分缓解。
- 失败案例说明：DoLa 不能创造模型没有掌握的事实知识。

一句话总结

DoLa 的价值在于低成本抑制部分“流畅但错误”的生成倾向，但它不是 factuality 问题的完整解法。

下一步提升方向

- ① GPU 上跑真实模型与 TruthfulQA, 补真实日志和 GPU 使用截图。
- ② 与官方 DoLa 结果对齐: 模型、split、layer 参数、relative top。
- ③ 加强 logits 可视化: 成功/失败样例的 answer/trap logits 曲线。
- ④ 扩展中文事实性数据集, 覆盖历史、地理、文学和科学常识。
- ⑤ 增加效率分析: latency、tokens/s、显存、candidate layers 数量影响。
- ⑥ 与 RAG、CoT、self-consistency 等方法做扩展对比。

代码与输出

- 本机实验: `scripts/run_local_dola_demo.py`
- 真实模型入口: `scripts/run_hf_mc_eval.py`
- 实验结果: `outputs/local_results_summary.csv`
- 案例分析: `outputs/case_studies.csv`
- 图表目录: `figures/`
- 报告: `report/report.md`

参考

DoLa: Decoding by Contrasting Layers Improves Factuality in Large Language Models, ICLR 2024.

<https://openreview.net/forum?id=Th6NyL07na>

谢谢